

Rapport Transfer Learning par extraction de features dans un CNN

RDFIA - TP 7

Etudiant : Numéro :

MAMOU Idles

DJEGHRI Amine 3801757

3803676

Décembre 2020

Partie 1 – Architecture VGG16

1- Le nombre de paramètres de VGG16 sachant que les couches fully connected comptent la majorité des paramètres du modèle :

Le nombre de poids d'une couche fully connected est le produit entre la dimension d'entrée et la dimension de sortie. La dimension d'entrée de la première couche fully connected est 7x7x512 (couche max-pooling), ainsi on aura :

7x7x512x4096 qui est le nombre de poids de la première couche fully connected 4096x4096 qui est le nombre de poids de la deuxième couche fully connected 4096x1000 qui est le nombre de poids de la troisième couche fully connected

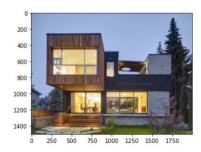
7x7x512x4096 + 4096x4096 + 4096x1000 = 124m

En comptant toutes les couches on a **138m :** En plus de compter les 3 couches citées plus haut on a les couches fully conv :

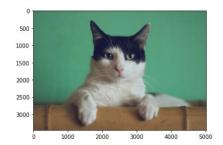
```
3*3*3*3*64 + 3*3*364*64 + 3*3*64*128+3*3*128*128+ 3*3*128*256 + 3*3*256*256+ 3*3*256*256 + 3*3*256*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*512 + 3*3*512*5
```

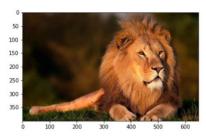
2- La taille de sortie de la dernière couche de VGG16 est de 1000. Elle correspond à une distribution de probabilité d'appartenance aux différentes classes produite par la fonction softmax.

3- Bonus Sur le notebook







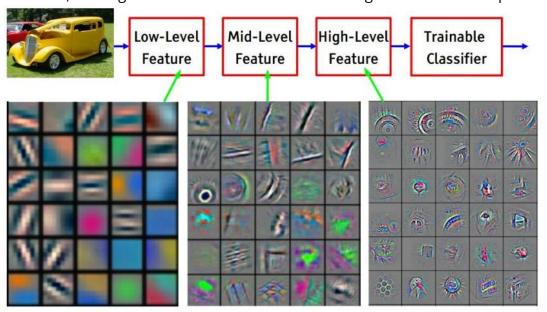


Les résultats de la classification sur des ces images sont plus ou moins correctes, le chat et le lion ont étaient correctement prédit, la maison a été prédite comme un entertainement center (peut-être à cause de la taille et des lumières) , et l'image de la piscine comme une Terrace

4- Bonus

Partie 2 – Transfer Learning avec VGG16 sur 15 Scene

- 5- On n'apprend pas directement vgg sur 15 scènes car la taille du dataset est trop petite pour permettre au réseau d'apprendre sachant qu'il contient un grand nombre de paramètres.
- 6- Le pré-apprentissage sur ImageNet permet au réseau d'extraire les features (caractéristiques d'une image) globales, ainsi utiliser cette étape de feature extraction sans modifier les poids afin d'aider à la classification des 15 scènes.
- 7- Les limites de cette approche par feature extraction sont : Si le réseau est entrainé sur un certain type d'images et qu'on lui fournit de nouvelles images avec des caractéristiques différentes de celles avec lesquelles il s'est entrainé, ces caractéristiques ne pourront peut-être pas être détectées car il est déjà entrainé sur d'autres caractéristiques.
- 8- La couche à laquelle sont extraites les features <u>représente le degré</u> <u>d'abstraction</u>, plus on avance dans le réseau et plus on aura des représentations avancées, l'image ci-dessous schématise en général cette explication.



9- Les images de 15 Scene sont en noir et blanc, alors que VGG16 attend des images RGB, afin de contourner ce problème on duplique 3 fois l'image (on duplique l'image sur chacun des channels)

10-Oui, il est possible de n'utiliser que le réseau de neurones, pour ça on utilise un réseau de neurones fully connected avec en sortie les 15 classes.
En prenant le vgg16, on modifie que les deux dernières couches pour remplacer les 1000 classes en 15 classes, on freeze alors les couches qui sont avant ces 2 couches pour éviter de modifier leurs poids avec le backward.

2.4 aller plus loin

- 11- Dans cette partie, on a testé plusieurs modifications (voir notebook tp7_question11):
 - Le changement de la couche à la quelle sont extraites les features affecte l'accuracy, plus on avance dans les couches et plus l'accuracy est meilleure.
 - Le changement du paramètre C du SVM affecte les scores.
 - La plus part des modèles pré entrainés testés sont : Resnet18 et GoogleNet et les scores obtenus ne varient pas significativement.